

Clasificación de Perfiles Operativos de Fallas Eléctricas

Clustering jerárquico + XGBoost

Christopher Piedrahita, Johan Sebastian Mendieta, Sebastian Torres

Teoría de Aprendizaje de Máquinas

18 de junio de 2026

Contexto del problema

Las empresas eléctricas registran grandes volúmenes de fallas, pero no todas tienen el mismo impacto operativo.

El problema principal es identificar qué eventos pueden representar mayor criticidad para apoyar:

- priorización de cuadrillas;
- análisis de fallas graves;
- reducción de tiempos de respuesta;
- toma de decisiones operativas basada en datos.

Objetivo del proyecto

Construir un sistema de aprendizaje automático capaz de clasificar eventos de falla eléctrica en perfiles operativos.

El modelo final predice:

- **BAJO_IMPACTO:** eventos de menor criticidad operativa. Representan fallas con menor afectación histórica, menor duración o menor prioridad frente a los grupos graves.
- **ALTO_IMPACTO_SUB0:** fallas graves de comportamiento intermedio. Agrupa eventos críticos que no son tan extremos como los otros subperfiles, pero que presentan impacto suficiente para requerir atención prioritaria.
- **ALTO_IMPACTO_SUB1:** fallas graves asociadas a mayor exigencia operativa o eléctrica. Representa eventos críticos con mayor severidad típica y mayor necesidad de respuesta técnica especializada.
- **ALTO_IMPACTO_SUB2:** fallas graves con posible componente climático o territorial. Agrupa eventos críticos relacionados con condiciones más adversas, mayor humedad, lluvia, tramos más largos o mayor dificultad de atención.

Flujo metodológico

- 1 Carga y depuración de la base histórica.
- 2 Eliminación de duplicados y columnas problemáticas.
- 3 Partición temporal: entrenamiento, validación y prueba.
- 4 Clustering inicial con $K = 2$.
- 5 Identificación del cluster de alto impacto mediante UITI y duración.
- 6 Subclustering del alto impacto con $K = 3$.
- 7 Entrenamiento de XGBoost para predecir perfiles operativos.
- 8 Evaluación con métricas de clasificación multiclase.

Variables utilizadas

El modelo usa variables disponibles antes o al inicio del evento:

- **Red eléctrica:** tipo, fases, neutro, longitud, calibre, material, aislamiento, altura, vegetación.
- **Tiempo:** año, mes, día, hora, día de semana.
- **Clima:** temperatura, humedad, presión, viento, ráfagas, nubosidad, radiación y precipitación.

Importante: UITI y duración se usan para construir los perfiles históricos, pero no como entradas finales del modelo XGBoost.

Clustering

El clustering busca agrupar eventos de falla que sean similares entre sí, sin usar una etiqueta supervisada inicial.

En K-Means, cada evento x_i se asigna al centroide más cercano:

$$c_i = \arg \min_k \|x_i - \mu_k\|^2$$

Luego, cada centroide se actualiza como el promedio de los puntos asignados:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

El objetivo es minimizar la distancia interna de los grupos:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

En el proyecto:

Clustering inicial y subclustering

El primer clustering usa $K = 2$ para separar:


fallas bajo/normal impacto vs fallas de alto impacto

Luego, el cluster de alto impacto se divide en tres subgrupos:

ALTO_IMPACTO $\rightarrow \{SUB0, SUB1, SUB2\}$

Esto permite pasar de una clasificación simple a una segmentación operativa más detallada.

Gráfica final de clusters



Modelo XGBoost

XGBoost construye un ensamble de árboles de decisión de forma secuencial.

La predicción se actualiza como:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta f_t(x_i)$$

Donde:

- x_i : evento de falla eléctrica.
- $f_t(x_i)$: árbol agregado en la iteración t .
- η : tasa de aprendizaje.
- $\hat{y}_i^{(t)}$: predicción acumulada.

Función objetivo de XGBoost

XGBoost busca minimizar error y complejidad:

$$Obj = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{t=1}^T \Omega(f_t)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

Esto significa que el modelo no solo intenta acertar, sino evitar árboles demasiado complejos.

Clasificación multiclase

Como existen cuatro perfiles, XGBoost genera una probabilidad por clase usando softmax:

$$P(y_i = k|x_i) = \frac{e^{z_{i,k}}}{\sum_{c=1}^K e^{z_{i,c}}}$$

La clase final se obtiene con:

$$\hat{y}_i = \arg \max_k P(y_i = k|x_i)$$

Así, el modelo no solo entrega una clase, sino una probabilidad asociada a cada perfil operativo.

Configuración del modelo

Parámetro	Valor	Interpretación
<i>n_estimators</i>	250	Número de árboles
<i>max_depth</i>	5	Complejidad controlada
<i>learning_rate</i>	0.07	Aprendizaje gradual
<i>subsample</i>	0.85	Muestra de filas por árbol
<i>colsample</i>	0.85	Muestra de variables por árbol
<i>objective</i>	multi:softprob	Probabilidades multiclase
<i>eval_metric</i>	mlogloss	Calidad probabilística

La configuración busca equilibrio entre precisión, generalización y tiempo de entrenamiento.

Se usaron métricas complementarias porque el accuracy por sí solo no es suficiente.

- **Accuracy:** porcentaje general de aciertos.
- **Precision macro:** confiabilidad de las predicciones por clase.
- **Recall macro:** capacidad para detectar cada perfil real.
- **F1 macro:** balance entre precisión y recall.
- **ROC-AUC macro:** separación probabilística entre perfiles.
- **Matriz de confusión:** análisis detallado de errores.

Interés empresarial

El sistema es de interés para una empresa eléctrica porque permite:

- identificar eventos de bajo y alto impacto;
- diferenciar tipos de fallas graves;
- apoyar la asignación de cuadrillas;
- priorizar eventos críticos;
- transformar datos históricos en inteligencia operativa.

El modelo funciona como una herramienta de apoyo a la decisión, no como reemplazo del criterio operativo.

Métricas de salida del modelo


Métrica	Resultado	Interpretación
Accuracy	95.03 %	Acierto general del modelo
F1 Macro	90.29 %	Balance entre clases, sin favorecer mayoritarias
F1 Weighted	95.05 %	Desempeño ponderado por cantidad de datos
Precision Macro	90.68 %	Confiabilidad al predecir cada perfil
Recall Macro	90.15 %	Capacidad para detectar cada perfil real
ROC-AUC Macro	99.61 %	Separación probabilística entre clases

Lectura general:

El modelo supera el objetivo mínimo del 80 % de accuracy y mantiene buen desempeño por clase. Esto indica que XGBoost aprendió a distinguir los perfiles operativos de falla, incluyendo las tres subclases de alto impacto.

Matriz de confusión

La matriz de confusión permite comparar las clases reales contra las clases predichas por el modelo.



Lectura:

- La diagonal representa los aciertos del modelo.
- Los valores fuera de la diagonal son errores de clasificación.
- Permite identificar qué perfiles se confunden entre sí.
- Es especialmente importante revisar si una falla grave fue clasificada como **BAJO IMPACTO**.

Conclusión

El proyecto integra clustering y XGBoost para construir un sistema de clasificación de perfiles operativos de fallas eléctricas.

- El clustering inicial separa eventos normales y críticos.
- El subclustering identifica tres tipos de fallas graves.
- XGBoost aprende a predecir estos perfiles usando variables técnicas, temporales y meteorológicas.
- La salida permite priorizar la atención operativa de eventos eléctricos.